

整体构成 bandit 式离线策略优化环 (非在线梯度); 记忆系统与人格优化经 θ_1/θ_2 两条更新通路打通

